

Raport- Wykrywanie naczyń dna siatkówki oka

Skład grupy (Grupa jednoosobowa)

Dawid Wnukiewicz 155858

Zastosowany język programowania oraz dodatkowe bibliotek

Język programowania: Python

Biblioteki i narzędzia:

- **OpenCV (cv2)** - przetwarzanie obrazów, operacje morfologiczne, filtry
- **NumPy** - operacje na tablicach, obliczenia numeryczne
- **Matplotlib** - wizualizacja wyników, wykresy, wyświetlanie obrazów
- **scikit-image** - filtry specjalistyczne (unsharp mask, frangi, rgb2gray)
- **scikit-learn** - klasyfikatory uczenia maszynowego, metryki oceny
- **imbalanced-learn** - równoważenie klas (RandomUnderSampler)
- **pandas** - analiza danych, obliczanie statystyk
- **joblib** - zapisywanie i ładowanie modeli
- **glob** - wyszukiwanie plików w katalogach
- **os** - operacje na systemie plików
- **gc** - zarządzanie pamięcią, garbage collection

Główne funkcje z bibliotek:

- **cv2.GaussianBlur** - redukcja szumu
- **cv2.createCLAHE** - adaptacyjna korekcja histogramu
- **cv2.fastNlMeansDenoising** - zaawansowana redukcja szumu
- **frangi** - wykrywanie struktur rurkowatych
- **RandomForestClassifier** - klasyfikator lasu losowego
- **RandomizedSearchCV** - optymalizacja hiperparametrów
- **confusion_matrix** - macierze pomyłek
- **train_test_split** - podział danych na zbiory

Opis zastosowanych metod

Przetwarzanie obrazu

Proces przetwarzania obrazów dna siatkówki oka w celu wykrywania naczyń krwionośnych składa się z trzech głównych etapów, zgodnie z wymaganiami projektu: Przetwarzanie wstępne, właściwe oraz końcowe.


Wstępne przetworzenie obrazu

Pierwszy etap rozpoczyna się od konwersji obrazu do przestrzeni kolorów RGB oraz normalizacji wartości pikseli do zakresu 0-1 poprzez dzielenie przez 255. Ta operacja zapewnia stabilność numeryczną w kolejnych krokach przetwarzania.

Kluczowym elementem wstępnego przetwarzania jest zastosowanie filtra wyostrającego (unsharp mask). W celach testowych oraz wizualizacyjnych został on zastosowany do każdego kanału kolorowego osobno. Filtr ten wykorzystuje odpowiednie parametry, co pozwala na zwiększenie kontrastu krawędzi i poprawieniu jakości obrazu przy zachowaniu naturalnego wyglądu.

Po wyostreniu następuje wyodrębnienie poszczególnych kanałów kolorowych (czerwony, zielony, niebieski) oraz konwersja do skali szarości z wykorzystaniem funkcji `rgb2gray`. Dodatkowo stosowana jest normalizacja intensywności za pomocą `exposure.rescale_intensity`, która zapewnia pełne wykorzystanie dostępnego zakresu dynamicznego.

Dzięki wizualizacji i testom okazuje się, że z kanału koloru zielonego otrzymujemy najwięcej szczegółów naczyń krwionośnych. Finalnie w wstępnym przetwarzaniu obrazu zostaje wyekstraktowany wyostrzony kanał zielony, który będzie obrabiany w dalszej części programu.



Właściwe przetwarzanie obrazu

Drugi etap koncentruje się na kanale zielonym, który w obrazach dna oka charakteryzuje się najlepszym kontrastem naczyń krwionośnych względem tła. Proces ten składa się z kilku kroków:

1. **Redukcja szumu:** Zastosowanie filtra Gaussa (`GaussianBlur`) z parametrem w celu wygładzenia drobnych zakłóceń przy zachowaniu struktur naczyniowych.
2. **Adaptacyjna korekcja histogramu (CLAHE):** Wykorzystanie algorytmu Contrast Limited Adaptive Histogram Equalization poprawia lokalny kontrast poprzez wyrównanie histogramu w małych obszarach obrazu, co jest szczególnie skuteczne w przypadku nierównomiernego oświetlenia charakterystycznego dla obrazów dna oka.
3. **Dodatkowa redukcja szumu:** Zastosowanie filtra `fastNIMeansDenoising` w celu usunięcia artefaktów powstałych podczas operacji CLAHE.
4. **Końcowe wyostrenie:** Kombinacja liniowa przetworzonego obrazu z obrazem rozmytym w celu dodatkowego podkreślenia struktur naczyniowych.

Po przygotowaniu kanału zielonego następuje zastosowanie **filtru Frangiego**, który jest specjalistycznym filtrem do wykrywania struktur rurkowatych w obrazach medycznych (naszych naczyń krwionośnych). Filt ten analizuje lokalne właściwości geometryczne obrazu, identyfikując obszary charakteryzujące się cechami typowymi dla naczyń krwionośnych.



Końcowe przetwarzanie obrazu

Trzeci etap obejmuje post-processing wyników filtru Frangiego w celu poprawy jakości detekcji:

1. **Binaryzacja:** Zastosowanie progowania automatycznego (THRESH_BINARY) do konwersji obrazu w skali szarości na maskę binarną.
2. **Usuwanie małych elementów:** Implementacja własnej funkcji `remove_small_elements` wykorzystującej analizę składowych połączonych. Funkcja ta usuwa obiekty o powierzchni mniejszej niż 800 pikseli oraz te, których wymiary (szerokość lub wysokość) nie przekraczają 150 pikseli. Takie podejście eliminuje drobne artefakty przy zachowaniu rzeczywistych struktur naczyniowych.
3. **Usuwanie brzegów:** Funkcja `remove_border` wykorzystuje przestrzeń kolorów HSV do identyfikacji obszaru siatkówki. Poprzez zastosowanie maski w zakresie HSV (dolna granica: , górna granica:) eliminowane są artefakty brzegowe powstające na granicy między siatkówką a tłem obrazu.



Normalizacja wyników

Na każdym etapie stosowana jest odpowiednia normalizacja wartości pikseli. Funkcja `normalize` zapewnia skalowanie wartości do zakresu 0-255 poprzez mnożenie przez współczynnik normalizacyjny obliczany jako stosunek docelowej wartości maksymalnej do rzeczywistej wartości maksymalnej w obrazie.

Krótkie uzasadnienie zastosowanego rozwiązania

Wybór opisanej strategii przetwarzania obrazów został podyktowany specyfiką obrazów dna siatkówki oka oraz charakterystyką naczyń krwionośnych w tego typu obrazach medycznych.

Kanał zielony został wybrany jako podstawa dalszego przetwarzania ze względu na najlepszy kontrast naczyń krwionośnych względem tła siatkówki. W obrazach naczyń krwionośnych pochtaniają światło zielone w większym stopniu niż tło, co skutkuje wyraźniejszą wizualizacją struktur naczyniowych w tym kanale kolorowym.

Filtr Frangiego został wybrany jako specjalistyczne narzędzie do wykrywania struktur rurkowatych w obrazach medycznych. Jego przewaga nad klasycznymi filtrami wykrywania krawędzi polega na analizie lokalnych właściwości geometrycznych obraz, co pozwala na selektywne wykrywanie struktur o charakterystycznych cechach typowych dla naczyń krwionośnych przy jednoczesnym tłumieniu innych elementów obrazu.

Rozwiązanie zostało tak naprawdę dopasowane do zestawu obrazów na których wykonywane było przetwarzanie. Na podstawie braków i metod prób i błędów, zostały dobrane odpowiednie techniki przetwarzania oraz filtrowania tak aby uzyskać jak najlepszy efekt.

Uczenie maszynowe

Przygotowanie danych

Proces przygotowania danych rozpoczyna się od skalowania obrazów w celu ograniczenia wymagań pamięciowych (żeby program krócej się wykonywał). Funkcja `resize_to_max_dimension` zapewnia, że żaden wymiar obrazu nie przekracza 3000 pikseli, zachowując jednocześnie proporcje oryginalnego obrazu poprzez zastosowanie interpolacji.

Wyznaczanie wycinków obrazu realizowane jest przez funkcję `slice_image_into_patches`, która dzieli obraz na nakładające się patche o rozmiarze 5x5 pikseli z krokiem 4-5 pikseli. Taki rozmiar patcha został wybrany jako kompromis między zachowaniem lokalnych cech naczyń krwionośnych a efektywnością obliczeniową. Dla każdego patcha etykieta klasyfikacyjna jest wyznaczana na podstawie wartości środkowego piksela w odpowiadającej masce eksperckiej.

Ekstrakcja cech z wycinków obejmuje obliczanie następujących deskryptorów dla każdego patcha:

- **Statystyki kanałów RGB:** średnia i odchylenie standardowe dla każdego z trzech kanałów kolorowych (6 cech)
- **Statystyki skali szarości:** średnia, odchylenie standardowe, wartość minimalna i maksymalna (4 cechy)
- **Cechy gradientowe:** średnia wartość bezwzględna gradientu w kierunku poziomym i pionowym, obliczana za pomocą operatora różnicowego (2 cechy)

Łącznie dla każdego patcha ekstraktowanych jest 12 cech liczbowych, które charakteryzują lokalne właściwości tekstury, kontrastu i orientacji struktur w obrazie.

Wstępne przetwarzanie zbioru uczącego

Ze względu na niezrównoważony rozkład klas charakterystyczny dla obrazów medycznych (piksele tła stanowią znaczną większość), zastosowano technikę Random Under Sampling z biblioteki `imbalanced-learn`. Metoda ta losowo usuwa próbki z klasy większościowej (tło) w celu zrównoważenia reprezentacji obu klas w zbiorze uczącym.

Dodatkowo wprowadzono ograniczenie liczby próbek do maksymalnie 300 patchy na obraz oraz całkowite ograniczenie zbioru uczącego do 10000 próbek w celu zarządzania wymaganiami pamięciowymi. Dane zostały podzielone na zbiór treningowy (80%) i walidacyjny (20%) z zachowaniem stratyfikacji klas.

Zastosowane metody uczenia maszynowego wraz z parametrami

Jako główny klasyfikator wybrano **Random Forest Classifier** ze względu na jego odporność na przeuczenie oraz zdolność do obsługi cech o różnych skalach bez konieczności normalizacji.

Optymalizacja hiperparametrów została przeprowadzona za pomocą RandomizedSearchCV z następującymi parametrami:

- **n_estimators**: - liczba drzew w lesie
- **max_depth**: 1 - maksymalna głębokość drzew
- **min_samples_split**: - minimalna liczba próbek do podziału węzła
- **min_samples_leaf**: 1 - minimalna liczba próbek w liściu

Przeszukiwanie zostało ograniczone do 6 iteracji z 2-krotną walidacją krzyżową, używając metryki F1 jako kryterium optymalizacji. W przypadku niepowodzenia optymalizacji, system automatycznie przechodzi do domyślnych parametrów: n_estimators=50, max_depth=8, min_samples_split=10.

Post-processing predykcji obejmuje morfologiczne wzmocnienie maski poprzez:

- Dylatację z jądrem eliptycznym 3x3 (2 iteracje)
- Wygładzenie filtrem Gaussa (5x5)
- Binarzację z progiem 50

Wyniki wstępnej oceny klasyfikatora

Wstępna ocena klasyfikatora została przeprowadzona na zbiorze walidacyjnym hold-out (20% danych treningowych). Model osiągnął dokładność walidacyjną na poziomie podawanym przez system podczas trenowania.

Metodologia testowania obejmuje:

- Predykcję na niezależnych obrazach testowych
- Obliczanie metryk dla każdego obrazu indywidualnie
- Wizualizację macierzy pomyłek dla każdego przypadku testowego
- Agregację wyników w postaci średnich wartości metryk

Zastosowane metryki oceny:

- **Accuracy**: ogólna dokładność klasyfikacji
- **Sensitivity (Recall)**: czułość względem klasy pozytywnej (naczynia)
- **Specificity**: swoistość względem klasy negatywnej (tło)
- **G-mean**: średnia geometryczna czułości i swoistości
- **A-metric**: średnia arytmetyczna czułości i swoistości

Uzasadnienie zastosowanego rozwiązania


Wybór Random Forest został podyktowany kilkoma czynnikami. Po pierwsze, algorytm ten charakteryzuje się wysoką odpornością na przeuczenie. Po drugie, nie wymaga skomplikowanego preprocessingu danych ani normalizacji cech, co upraszcza pipeline przetwarzania. Dodatkowo jest bardzo popularny i wykorzystywany w projektach.

Rozmiar patcha 5x5 został wybrany jako optymalny kompromis między zachowaniem kontekstu lokalnego a efektywnością obliczeniową. Mniejsze patche mogłyby nie zawierać wystarczających informacji o strukturze naczyń, podczas gdy większe znacznie zwiększyłyby złożoność obliczeniową.

Zastosowanie under-sampling wynika z ograniczeń pamięciowych oraz faktu, że klasa większościowa (tło) zawiera wiele redundantnych próbek o podobnych charakterystykach. Redukcja tej klasy nie prowadzi do znaczącej utraty informacji.

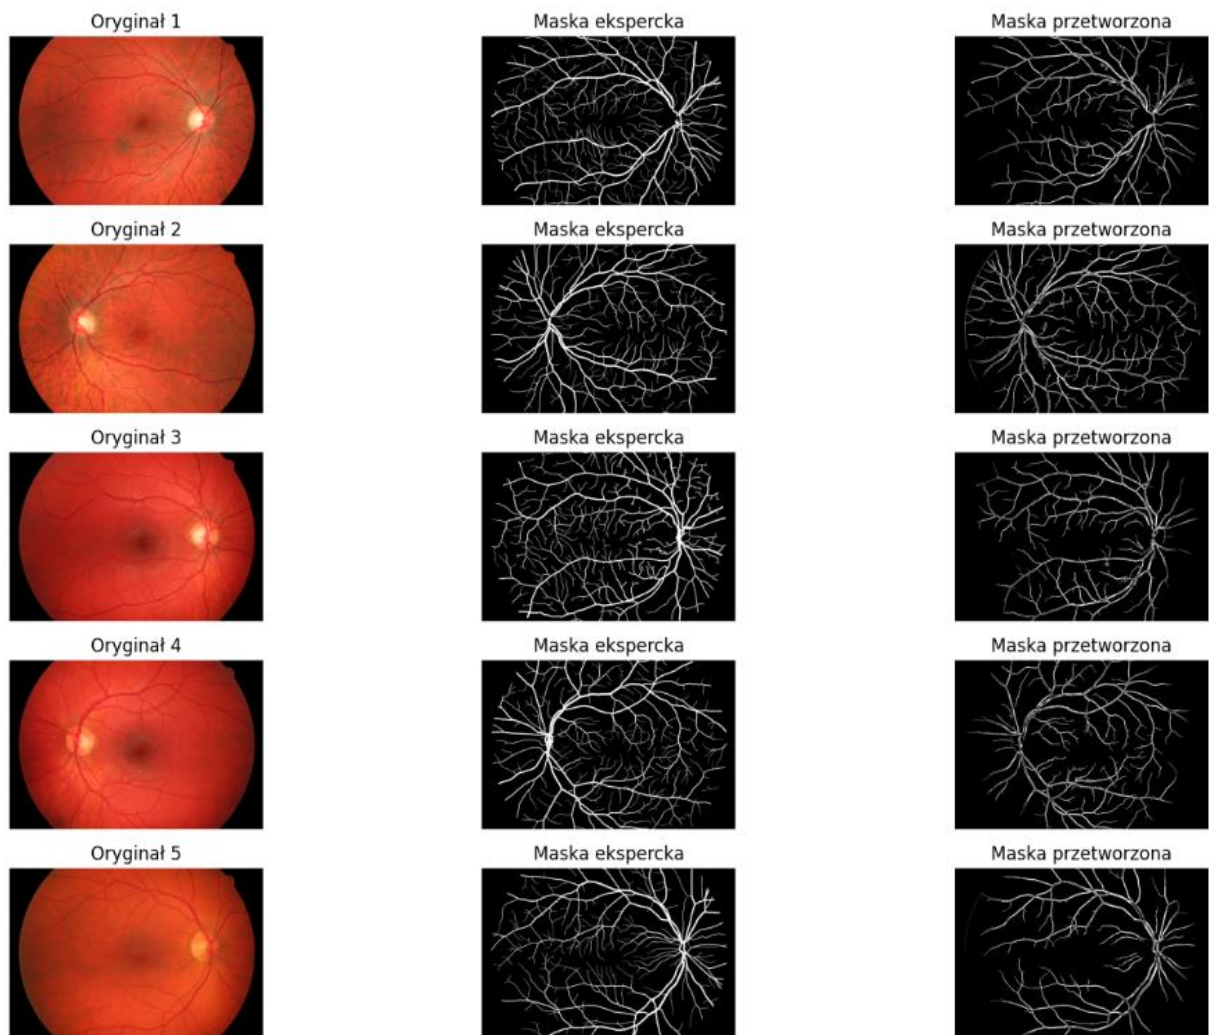
Wybrane cechy koncentrują się na podstawowych właściwościach statystycznych i teksturalnych, które są charakterystyczne dla naczyń krwionośnych: lokalne zmiany intensywności, kontrast oraz orientacja struktur. Cechy gradientowe są szczególnie istotne dla wykrywania struktur typowych dla naczyń krwionośnych.

Post-processing morfologiczny został wprowadzony w celu kompensacji fragmentacji wyników klasyfikacji punktowej oraz wzmocnienia ciągłości wykrytych struktur naczyniowych. Dzięki takiemu końcowemu przetworzeniu, obraz jest wyrazisty i miły w odbiorze.




Wizualizacja wyników działania programu

Przetwarzanie obrazów



Uczenie maszynowe



Wnioski

Filtr Frangiego wydaje się być lepszy dla aplikacji wymagających wysokiej precyzji, Random Forest dla pełnej detekcji wszystkich struktur naczyniowych. Filtr Frangiego daje "czyste" ale niepełne maski - wysoką precyzję kosztem czułości. Random Forest generuje "bogatsze" ale zaszumione maski - wysoką czułość kosztem precyzji.

Filtr Frangiego bardzo precyzyjnie wykrywa główne naczynia - wyraźne kontury, minimalne fałszywe detekcje. Za to gubi cienkie naczynia obwodowe, fragmentacje struktur, ma problemy z ciągłością.

Random Forest lepiej wykrywa drobne naczynia, widoczna jest większa ciągłość struktur, adaptacja do lokalnych wzorców. Za to jest więcej szumu i artefaktów, mniej precyzyjne kontury, tendencja do nadmiernej detekcji.

Analiza wyników działania programu

Analiza została przeprowadzona na 5 obrazach testowych z wykorzystaniem dwóch metod: przetwarzania obrazów (filtr Frangiego) oraz uczenia maszynowego (Random Forest).

Analiza i porównanie obu podejść:

Obraz 1

- **Przetwarzanie obrazów:** accuracy 94.72%, sensitivity 56.37%, specificity 99.07%
- **Uczenie maszynowe:** accuracy 81.22%, sensitivity 75.96%, specificity 81.82%

Obraz 1 charakteryzuje się dobrze widocznymi naczyniami głównymi. Filtr Frangiego osiągnął bardzo wysoką swoistość (99.07%), co oznacza minimalne fałszywe detekcje, ale kosztem niższej czułości (56.37%). Random Forest wykazał lepszą czułość (75.96%), wykrywając więcej rzeczywistych naczyń, ale z większą liczbą fałszywych pozytywów.

Obraz 2

- **Przetwarzanie obrazów:** accuracy 95.82%, sensitivity 68.12%, specificity 98.85%
- **Uczenie maszynowe:** accuracy 79.65%, sensitivity 78.35%, specificity 79.79%

Obraz 2 okazał się najlepszy dla metody przetwarzania obrazów, osiągając najwyższą dokładność (95.82%) i dobrą czułość (68.12%). Uczenie maszynowe pokazało zrównoważone wyniki między czułością a swoistością, ale z niższą ogólną dokładnością.

Obraz 3

- **Przetwarzanie obrazów:** accuracy 93.73%, sensitivity 46.63%, specificity 99.29%
- **Uczenie maszynowe:** accuracy 71.11%, sensitivity 81.08%, specificity 69.94%

Obraz 3 przedstawia największe wyzwanie dla filtru Frangiego z najniższą czułością (46.63%), sugerując obecność bardzo cienkich naczyń trudnych do wykrycia. Random Forest radzi sobie znacznie lepiej z wykrywaniem tych struktur (81.08% czułości), ale kosztem zwiększonych fałszywych detekcji.

Obraz 4

- **Przetwarzanie obrazów:** accuracy 95.03%, sensitivity 53.97%, specificity 99.30%
- **Uczenie maszynowe:** accuracy 73.63%, sensitivity 82.41%, specificity 72.72%

Obraz 4 potwierdza wzorec obserwowany w poprzednich przypadkach - filtr Frangiego utrzymuje bardzo wysoką swoistość przy umiarkowanej czułości, podczas gdy Random Forest lepiej wykrywa naczynia ale z większą liczbą artefaktów.

Obraz 5

- **Przetwarzanie obrazów:** accuracy 95.44%, sensitivity 55.27%, specificity 99.42%
- **Uczenie maszynowe:** accuracy 86.90%, sensitivity 53.38%, specificity 90.23%

Obraz 5 jest wyjątkowy - Random Forest wykazał najniższą czułość (53.38%) spośród wszystkich testowanych obrazów, co może wskazywać na specyficzne charakterystyki tego obrazu, które utrudniają klasyfikację uczenia maszynowego.

Porównanie metod

Przetwarzanie obrazów (Filtr Frangiego)

- **Średnie wyniki:** accuracy 94.95%, sensitivity 56.07%, specificity 99.19%
- **Mocne strony:** Wyjątkowo wysoka swoistość (99.19%), minimalne fałszywe detekcje, stabilne wyniki między obrazami
- **Słabe strony:** Niska czułość (56.07%), gubienie cienkich naczyń obwodowych, fragmentacja struktur

Uczenie maszynowe (Random Forest)

- **Średnie wyniki:** accuracy 78.50%, sensitivity 74.23%, specificity 78.90%
- **Mocne strony:** Znacznie lepsza czułość (74.23%), wykrywanie drobnych struktur naczyniowych
- **Słabe strony:** Niższa ogólna dokładność, więcej fałszywych pozytywów, większa zmienność wyników

Analiza metryk dla danych nie zrównoważonych

G-mean (średnia geometryczna)

- Przetwarzanie obrazów: 74.43%
- Uczenie maszynowe: 76.00%

A-metric (średnia arytmetyczna)

- Przetwarzanie obrazów: 77.63%
- Uczenie maszynowe: 76.57%

Metryki dla danych nie zrównoważonych pokazują podobną skuteczność obu metod, z niewielką przewagą uczenia maszynowego w G-mean i przetwarzania obrazów w A-metric.

Wnioski

Filtr Frangiego jest preferowany w sytuacjach wymagających wysokiej precyzji diagnostycznej, gdzie fałszywe pozytywne mogą prowadzić do błędnej interpretacji. Random Forest lepiej sprawdza się w zastosowaniach badawczych wymagających pełnej detekcji wszystkich struktur naczyniowych.

Obrazy z wyraźnymi naczyniami głównymi (obraz 2) faworyzują przetwarzanie obrazów, podczas gdy obrazy z drobnymi strukturami (obraz 3) lepiej obsługuje uczenie maszynowe.